

T.C
KONYA TEKNİ ÜNİVERSİTESİ BİLGİSAYAR MÜHENDİSLİĞİ
BİLGİSAYAR MÜHENDİSLİĞİ UYGULAMASI – 1/2
(BİTİRME PROJESİ-1/2) FİNAL RAPOR FORMU

Öğrencinin Adı- Soyadı			
Numarası:		İmzası:	
Proje Danışmanı Adı Soyadı:		İmzası:	
Sınav Tarihi:	30.05.2025		

Projenin Adı: Segmentasyon, Öznitelik Mühendisliği ve Çoklu Hastalık Sınıflandırma ile Göz Hastalık Teşhisi

PROJEDE YAPILAN ÇALIŞMALARIN ÖZETİ

• **Literatür Araştırması**

Proje sürecinin ilk aşamasında göz hastalıklarının tespitiyle ilgili mevcut literatür incelenmiştir. Göz hastalıklarının teşhisinde kullanılan görüntü işleme teknikleri ve yapay zeka yöntemleri üzerine yapılan çalışmalardaki yöntemler ve sonuçlar detaylı şekilde analiz edilmiştir. Bu araştırmalar sonucunda, fundus görüntülerinin analizi ve bu görüntülerdeki damar yapıları, optik sinir diski gibi önemli özniteliklerin incelenmesinin, göz hastalıklarının erken teşhisinde kritik bir rol oynadığı tespit edilmiştir.

• **Veri Seti Seçimi**

Çalışmada kullanılacak uygun veri setlerinin seçimi büyük önem taşımıştır. İlk aşamada Kaggle'dan alınan veri seti üzerinde çalışma yapılmıştır. Bu veri seti her sınıfın yaklaşık 1000 görüntüye sahip olduğu Normal, Diyabetik Retinopati, Katarakt ve Glokom retinal görüntülerinden oluşmaktadır. Görüntüler IDRiD, Oculur tanıma, HRF gibi çeşitli kaynaklardan toplanmıştır.

• **Görüntü İşleme Teknikleri**

Görüntü işleme aşamasında fundus görüntüleri üzerinde aşağıdaki teknikler uygulanmıştır:

- Histogram eşitleme
- Kontrast germe
- Konvolüsyon teknikleri
- Gözdeki damar yapılarının belirginleştirilmesi için erozyon/aşınma gibi morfolojik işlemler
- Segmentasyon

Bu teknikler, görsel özelliklerin çıkarılması ve hastalıkların tespitine yönelik özniteliklerin belirlenmesinde temel rol oynamıştır. Özellikle damar yapılarının ve optik diskin net bir şekilde tanımlanması, göz hastalıklarının doğru teşhisi için kritik adımlardır.

- **Glokom Hastalığı Tespiti**

İlk olarak glokom hastalığının tespitine yönelik çalışmalar yapılmıştır. Bu kapsamda:

- Optik sinir diskinin şekli
- Göz içi basınç belirtileri
- Retinal sinir lifi kaybı

gibi glokomun belirgin özellikleri incelenmiştir. Bu öznitelikler, görüntü işleme teknikleri ile çıkarılarak glokomun varlığı üzerine analizler gerçekleştirilmiştir. Fundus görüntülerinde yapılan iyileştirmeler ve optik sinir diski segmentasyonu, glokom hastalığının başarılı bir şekilde teşhis edilmesini sağlamıştır.

- **Diyabetik Retinopati Hastalığı Tespiti**

Glokom hastalığının tespiti için görüntü işleme adımları tamamlandıktan sonra diyabetik retinopati hastalığının tespit edilmesine yönelik çalışmalara başlanmıştır. Diyabetik Retinopati, yüksek kan şekeri nedeniyle gözün retina tabakasındaki damarların hasar görmesi sonucunda ortaya çıkan bir hastalıktır.

- Nonproliferatif (başlangıç evresi): Bozuk damarlardan sıvı sızması ve retinada kanamalara sebep olur, genellikle görme yetisi etkilenmez.
- Proliferatif (ileri evre): Retina tabakasındaki damarların ileri derecede bozulmasına bağlı beslenemeyen bölgeler oluşur ve yeni damarlar gelişir. Bu damarlar ince ve kırılabilir olduğundan göz içi kanamaya neden olabilir.

Diyabetik retinopati tespiti için segmentasyon sonuçlarından (optik disk, kan damarları, mikroanevrizmalar, eksüdalar) öznitelikler çıkarılması için çalışmalar yapılmıştır. Bu amaçla:

- Train için 100 hasta, 100 normal görüntü
- Test için 50 hasta, 50 normal görüntü ayrılmıştır.

Segmentli görseller kaydedildikten sonra gerekli istatistiksel öznitelikler çıkarılmış ve oluşturulan yeni veri seti makine öğrenmesi modellerine verilerek en yüksek başarıyı sağlayan model tespit edilmiştir.

- **Derin Öğrenme Modelleri ile Geliştirme**

Projenin ikinci aşamasında daha çok hastalığı barındıran Kaggle'dan alınan veri seti üzerinden hastalıkları tespit edecek derin öğrenme modelleri geliştirilmeye başlanmıştır. Bu süreçte:

- Aynı veri setiyle yapılmış çalışmalar incelenmiştir
- Farklı derin öğrenme modelleri denenmiştir
- Her model için parametreler optimize edilmiştir
- Sonuçlar diğer çalışmalarla karşılaştırılmıştır
- En iyi sonucu veren modelin detaylı analizi yapılmıştır

Derin öğrenme teknikleri ile daha fazla doğruluk ve genelleme sağlanarak, göz hastalıklarının teşhisi üzerine yapılan analizler güçlendirilmiştir.

PROJENİN AMACI ve ÖNEMİ

Projenin Amacı:

Bu proje, göz hastalıklarının fundus (göz arkası) görüntülerinden doğru bir şekilde teşhis edilmesine yardımcı olacak görüntü işleme teknikleri ve yapay zeka yöntemlerinin geliştirilmesine odaklanmaktadır. Projenin temel amacı, fundus görüntülerindeki karakteristik özellikleri (damar yapıları, optik sinir diski, mikroanevrizmalar, eksüdalar vb.) analiz ederek glokom ve diyabetik retinopati gibi yaygın göz hastalıklarının erken ve doğru bir şekilde tespit edilmesini sağlayacak bir sistem ortaya koymaktır. Bu amaç doğrultusunda, farklı görüntü işleme adımları uygulanarak görüntü kalitesinin artırılması, ilgili yapıların belirginleştirilmesi ve bu yapılardan anlamlı özniteliklerin çıkarılması hedeflenmektedir. Elde edilen öznitelikler kullanılarak makine öğrenmesi yöntemleriyle sınıflandırma yapılacak, daha sonra katarakt, diyabetik retinopati, glokom ve normal olmak üzere dört farklı hastalığın teşhisi için öğrenme modelleri kullanılarak gerçekleştirilecek ve böylece göz hastalıklarının otomatik teşhisi mümkün kılınacaktır.

Projenin Önemi:

Göz hastalıklarının erken teşhisi ve doğru tedavi yöntemlerinin uygulanması, görme kaybının önlenmesi ve hasta yaşam kalitesinin artırılması açısından büyük önem taşımaktadır. Özellikle glokom ve diyabetik retinopati gibi sinsi ilerleyen hastalıklar, erken evrelerde belirgin semptomlar göstermeyebilir ve bu durum tanı koymayı geciktirebilir. Fundus görüntüleri, gözün arka kısmındaki retina, optik sinir diski ve kan damarları gibi önemli yapıları detaylı bir şekilde görüntüleme imkanı sunar. Bu görüntülerin doğru analizi, göz hastalıklarının erken evrede tespit edilmesinde kritik bir rol oynar.

Bu proje, görüntü işleme ve yapay zeka tekniklerini kullanarak fundus görüntülerinden otomatik olarak hastalık tespiti yapabilen bir sistem geliştirerek aşağıdaki açılardan önemli katkılar sağlamayı amaçlamaktadır:

- **Erken Teşhis İmkânı:** Geliştirilen sistem, göz hastalıklarının erken evrelerde tespit edilmesine yardımcı olarak zamanında müdahale ve tedavi imkanlarını artırabilir, böylece görme kaybı riskini azaltabilir.
- **Doğru Teşhis Oranlarının Artırılması:** Görüntü işleme teknikleri ile fundus görüntülerindeki ince detaylar daha belirgin hale getirilerek ve yapay zeka algoritmaları ile bu detaylar analiz edilerek teşhis doğruluğu artırılabilir.
- **Hızlı ve Verimli Tarama:** Otomatik teşhis sistemleri, büyük miktarda fundus görüntüsünün hızlı ve verimli bir şekilde taranmasına olanak tanıyarak hekimlerin iş yükünü azaltabilir ve daha fazla hastaya ulaşılmasını sağlayabilir.
- **Yaygın Göz Hastalıklarına Odaklanma:** Projede özellikle glokom ve diyabetik retinopati gibi yaygın ve ciddi göz hastalıklarının tespiti hedeflenerek geniş bir hasta kitlesine fayda sağlanması amaçlanmaktadır.

Literatüre Katkı: Proje sürecinde elde edilen bulgular ve geliştirilen yöntemler, yol gösterici olabilir.

KAYNAK ARAŞTIRMASI

Hatanaka vd. glokom tespitinde kupa alanının zor tespit edilmesinden yola çalışmalarında optik disk üzerinde dikey bir profil kullanılarak çanak-disk oranını ölçmek için yeni bir yöntem önermiştir. Önerilen yöntemde ilk olarak kan damarları görüntüden temizlenmiş ve ardından canny kenar algılama filtresi kullanılarak disk kenar tespiti yapılmıştır. Daha sonra renkli görüntü verisi üzerinde kupa-disk oranı hesaplanmıştır. 25' i glokoma olan toplamda 79 adet görüntü verisinin kullanıldığı yöntemde %80 hassasiyet ve %85 özgüllük başarıımı elde edilmiştir [1].

Carrillo vd., Kolombiya özelinde yaygın görülen göz tansiyonu hastalığını ele almış ve bu hastalığın otomatik olarak tespiti ile ilgili yapay zekâ tabanlı yeni bir hesaplama yöntemi önermiştir. Önerilen yeni yöntemde kupa ve disk boyutu arasındaki eşik değere göre yapılan yeni ölçüm literatürdeki diğer disk segmentasyon yöntemlerine göre başarıımı daha yüksektir. Yeni yöntem glokom tespitinde %85 başarı göstermiştir [2].

Carrillo ve ekibi, Kolombiya'da yaygın görülen göz tansiyonu hastalığını ele almış ve bu hastalığın otomatik olarak tespiti için yapay zekâ tabanlı yeni bir hesaplama yöntemi önermiştir. Bu yeni yöntem, kupa ve disk boyutu arasındaki eşik değere dayalı olarak yapılan yeni ölçümler sayesinde, literatürdeki diğer disk segmentasyon yöntemlerine kıyasla daha yüksek bir başarı elde etmiştir. Araştırmanın sonuçlarına göre, yeni yöntem glokom tespitinde %88.5 başarı göstermiştir [3].

Carrillo, J., Bautista, L., Villamizar, J., Rueda, J., & Sanchez, M. yaptığı bu çalışmada glokom tespiti için çeşitli görüntü işleme teknikleri incelenmiştir. Yazarlar, glokomun erken teşhisi için önemli olan optik disk ve cup-to-disc oranının (CDR) değerlendirilmesine odaklanmıştır. Çalışmada, üç ana yöntem önerilmektedir: çoklu eşikleme tekniklerine dayalı morfolojik işlemler, aktif kontur modelleri ve bölge büyütme segmentasyon teknikleri.

Sonuç olarak, önerilen yöntemlerin büyük veri setleri ile birleştirilerek daha iyi sonuçlar elde edilebileceği belirtilmektedir. Bu çalışma, glokomun otomatik tespiti için yeni bir çerçeve sunmakta ve gelecekteki araştırmalara zemin hazırlamaktadır.[4]

Dhumane, C. D., & Patil, S. B. bu çalışmasında glokom tespitinde kullanılan otomatik bir sistemin geliştirilmesini hedeflemektedir. Glokom, optik sinir başını etkileyen ve görme kaybına yol açabilen bir göz hastalığıdır. Çalışmada, optik disk ve optik çukur arasındaki oranı (cup to disc ratio - CDR) ölçerek glokomun tespit edilmesi önerilmektedir.

CDR Ölçümü: Optik disk ve çukur sınırlarının tespiti, çeşitli segmentasyon teknikleri ile gerçekleştirilir.

Bu teknikler arasında şablon tabanlı, deformable model tabanlı ve pikselleştirme sınıflandırma yöntemleri bulunmaktadır. Süperpiksel Segmentasyonu: Yeni bir yaklaşım olarak, süperpiksel sınıflandırma tabanlı segmentasyon yöntemi önerilmektedir. Bu yöntem, doğru disk ve çukur tespiti için basit lineer iteratif kümeleme algoritması ve merkez-çevre istatistikleri kullanmaktadır.[5]

Retina görüntü işleme çalışmaları, göz hastalıklarının erken teşhisi ve tedavisi açısından büyük önem taşımaktadır. Bu bağlamda, Melo ve arkadaşları (2020), diyabetik retinopati (DR) taramasında kullanılan mikroanevrizma tespiti için kayar bant filtresi (SBF) tabanlı bir yöntem geliştirmiştir. Çalışmada, renk, kontrast ve şekil özelliklerini birleştirerek mikroanevrizmaların tespitini otomatikleştiren bir sınıflandırıcı modeli önerilmiştir. Bu yöntem, dört farklı veri kümesinde test edilmiş ve hassasiyet ile yalancı pozitif oranları açısından mevcut yöntemlerle karşılaştırılmıştır [6]

Benzer şekilde, Tanyıldızı ve Okur (2016), retina görüntülerindeki kan damarlarının belirlenmesi üzerine yaptıkları çalışmada, OpenCV kütüphanesi kullanarak median ve Gauss filtreleme, eşikleme ve kontur bulma tekniklerini uygulamışlardır. Çalışma, diyabetik retinopati gibi hastalıkların teşhisinde kullanılabilecek hızlı ve açık kaynaklı bir yöntem sunmuştur. Özellikle, OpenCV'nin hız ve esneklik avantajları sayesinde görüntü işleme sürecinin MATLAB'a göre daha verimli olduğu vurgulanmıştır.[7]

Mikroanevrizmaların tespiti, diyabetik retinopati teşhisinde önemli bir adımdır ve bu alanda çeşitli görüntü işleme teknikleri kullanılmaktadır. Patwari ve arkadaşları (2013), diyabetik retinopati lezyonlarından mikroanevrizmaların tespiti ve sayılması için bir algoritma geliştirmiştir. Çalışmada, yüksek çözünürlüklü fundus görüntülerine ön işleme, histogram eşitleme ve yoğunluk dönüşüm fonksiyonları uygulanarak mikroanevrizmalar belirginleştirilmiştir. Mikroanevrizmaların sınırları, morfolojik işlemler ve eşikleme teknikleri ile segmente edilmiştir. Çalışmanın sonucunda, önerilen algoritmanın %96 doğruluk ve %92 duyarlılık oranına ulaştığı belirtilmiştir. Bu algoritma, mikroanevrizmaların anjiyografi olmadan erken aşamalarda tespitine olanak tanımaktadır.[8]

Maison ve arkadaşları (2019), retinal hastalıkların erken teşhisi için damar segmentasyonu üzerine bir çalışma gerçekleştirmiştir. Çalışmada, retinal fundus görüntüleri üzerinde Gauss filtresi kullanılarak damar yapıları belirginleştirilmiş ve bu yöntem, DRIVE veri tabanındaki görüntüler üzerinde test edilmiştir. Segmentasyon işlemi sırasında, görüntülerin ön işleme aşamaları olarak yeşil kanal çıkarımı, histogram eşitleme ve morfolojik açma yöntemleri kullanılmıştır. Değerlendirme sonuçlarına göre, önerilen yöntem %95.72 doğruluk, %96.90 duyarlılık ve %82.10 özgüllük değerleriyle başarılı bir performans sergilemiştir. Araştırmacılar, bu yöntemin ince ve zor görünen damarları belirginleştirerek retinal hastalıkların tespiti için uygun bir araç olduğunu belirtmişlerdir (Maison et al., 2019).[9]

Timothy Spencer, John A. Olson, Kenneth C. McHardy, Peter F. Sharp ve John V. Forrester tarafından yapılan "An Image-Processing Strategy for the Segmentation and Quantification of Microaneurysms in Fluorescein Angiograms of the Ocular Fundus" başlıklı çalışma, diyabetik retinopati gibi hastalıkların erken teşhisinde kullanılabilecek yenilikçi bir görüntü işleme stratejisini incelemektedir (Spencer et al., 1996). Bu çalışma, dijital görüntü işleme teknikleri kullanarak mikroanevrizmaların tespit edilmesi ve nicelenmesi üzerine yoğunlaşmaktadır. Çalışma kapsamında, ön işleme aşamalarından sonra bilinear top-hat dönüşümü ve eşleştirilmiş filtreleme kullanılarak görüntülerin başlangıçta segmentasyonu sağlanmaktadır. Bu işlenen görüntünün eşiklenmesi sonucu, aday mikroanevrizmaları içeren bir ikili görüntü elde edilmektedir. Yenilikçi bir bölge genişletme algoritması kullanılarak işaretlenen her bir nesne tamamen belirlenmekte ve sonrasında boyut, şekil ve enerji özellikleri analiz edilerek nihai mikroanevrizma segmentasyonu gerçekleştirilmektedir.[10]

Syna Sreng, Noppadol Maneerat ve Kazuhiko Hamamoto tarafından yazılan "Automated Microaneurysms Detection in Fundus Images Using Image Segmentation" başlıklı çalışma, diyabetik retinopati gibi göz hastalıklarının erken teşhisinde kullanılabilecek otomatik bir mikroanevrizma tespit yöntemini incelemektedir (Sreng, Maneerat, & Hamamoto, 2017). Bu çalışma, fundus görüntülerinde mikroanevrizmaları tespit etmek için görüntü segmentasyon tekniklerini kullanmayı önermektedir. Çalışmanın metodolojisi dört ana adımdan oluşmaktadır: (1) Ön işleme, (2) Mikroanevrizmaların Çıkarılması, (3) Küçük Parlak Özelliklerin Filtrelenmesi ve (4) Mikroanevrizma Tespiti. İlk olarak, görüntülerin gürültüsünü azaltmak ve kontrastı iyileştirmek amacıyla ön işleme uygulanır. Ardından, Canny kenar tespiti ve maksimum entropi eşikleme kullanılarak mikroanevrizmalar belirlenir. Mikroanevrizmalar küçük kırmızı noktalar ve dairesel şekiller olarak tanımlanır ve bu özellikler, diğer lezyonlardan ve fundus görüntüsünün anatomik yapılarından ayırt edilmelerini sağlar. Çalışmanın bulguları, otomatik tespit yönteminin doğruluk oranının %90 olduğunu ve ortalama işleme süresinin görüntü başına 9.53 saniye olduğunu göstermektedir. Bu sonuçlar, özellikle sınırlı sayıda göz doktorunun bulunduğu bölgelerde, diyabetik retinopati gibi hastalıkların erken teşhisinde otomatik sistemlerin önemini vurgulamaktadır.[11]

Bu makale, derin öğrenme ve transfer öğrenimi tekniklerini kullanarak göz hastalıklarını sınıflandırma üzerine odaklanıyor. Araştırma, retinaya ait fundus görüntülerini kullanarak diyabetik retinopati, katarakt ve glokom gibi göz hastalıklarının erken teşhisini hedefliyor. Bu sınıflandırma süreci, Convolutional Neural Networks (CNN) gibi derin öğrenme algoritmalarını ve önceden eğitilmiş modelleri içeriyor. Öne çıkan bazı noktalar: Çalışmada kullanılan modeller arasında CNN, MobileNet, DenseNet121, ResNet ve EfficientNetB3 yer alıyor. MobileNet modeli en yüksek doğruluk oranlarını (%99.94 eğitim ve %95.67 doğrulama) sağlarken, EfficientNetB3 modeli de benzer yüksek performanslar sergiliyor. Veri seti Kaggle platformundan alınmış ve diyabetik retinopati, katarakt, glokom ve normal göz görüntülerini

içeriyor. Veri artırma ve ön işleme teknikleri uygulanarak sınıflandırma doğruluğu artırılmış. Bu yaklaşım, sağlık hizmetlerine erişimin kısıtlı olduğu bölgelerde teşhis sürecini otomatikleştirerek sağlık hizmetlerinin erişilebilirliğini artırma potansiyeline sahip.[12]

Bu çalışma, evrimsel sinir ağları (CNN) ve transfer öğrenme teknikleri kullanılarak, normal göz ile diyabetik retinopati, katarakt ve glokom gibi hastalıklar arasındaki farklılıkların otomatik olarak sınıflandırılmasını incelemektedir. Geleneksel CNN modeline kıyasla, pre-trained EfficientNet mimarisiyle gerçekleştirilen transfer öğrenme yöntemi, %84 yerine %94 doğruluk oranı elde etmiştir. Makale, derin öğrenme tabanlı görüntü işleme yöntemlerinin, tıbbi görüntü analizi ve erken teşhis açısından sağlayabileceği potansiyel avantajları vurgulamakta ve bu alanda otomatik sınıflandırma sistemlerinin geliştirilmesinde transfer öğrenmenin etkinliğini ortaya koymaktadır.[13]

Jatmoko ve arkadaşları (2024), DenseNet ve EfficientNetB3 tabanlı transfer öğrenme modellerini kullanarak katarakt, diyabetik retinopati, glokom ve normal olmak üzere dört farklı göz hastalığının sınıflandırılmasını incelemiştir. Çalışmada, Kaggle üzerinden temin edilen 4217 adet göz görüntüsü farklı eğitim–doğrulama–test bölünme şemalarıyla (ör. %70:10:20) değerlendirilmiş; sonuçlar, EfficientNetB3 modelinin %95.66 doğruluk oranıyla DenseNet modeline göre (yaklaşık %78.59 doğruluk) üstün performans sergilediğini göstermiştir. Bu bulgular, erken teşhis ve tedavi sürecinde daha güvenilir sınıflandırma yöntemlerinin geliştirilmesinde önemli katkılar sağlamaktadır. [14]

Chavan ve arkadaşları (2024), göz hastalıklarının (diyabetik retinopati, glokom, katarakt) otomatik tanısında derin öğrenme yaklaşımlarını kullanarak, konvolüsyonel sinir ağları (CNN) bazlı DenseNet121 ve Xception modellerini, geleneksel makine öğrenmesi algoritmaları olan Random Forest ve Support Vector Machine ile entegre eden hibrit bir sistem geliştirmiştir. Çalışma; mevcut manuel tanı yöntemlerinin yetersizliklerini aşmak, veriden otomatik ve tutarlı özellik çıkarımı sağlamak ve sınıf dengesizliği, etiketli veri eksikliği gibi zorlukları veri artırma ve transfer öğrenme gibi stratejilerle gidermeyi amaçlamaktadır. Önerilen yöntem, yüksek doğruluk oranları elde ederek, erken teşhis ve etkin tedavi için potansiyel bir araç sunmaktadır.[15]

MATERYAL VE METOT

Bu projede, göz hastalıklarının tespiti için fundus görüntüleri üzerinde çeşitli görüntü işleme teknikleri uygulanmış ve makine öğrenmesi ile derin öğrenme yöntemleri kullanılmıştır. Çalışmanın farklı aşamalarında kullanılan materyal ve metotlar aşağıda detaylandırılmıştır:

Veri Setleri

Projenin farklı aşamalarında iki temel veri seti kullanılmıştır:

- **İlk Aşama (Glokom Tespiti):**

Kaggle platformundan elde edilen bir veri seti kullanılmıştır. Bu veri seti, her biri yaklaşık 1000 görüntü içeren Normal, Diyabetik Retinopati, Katarakt ve Glokom olmak üzere dört farklı sınıfa ait fundus retina görüntülerini içermektedir. Görüntüler IDRİD, Ocular tanıma, HRF gibi çeşitli kaynaklardan toplanmıştır.

- **İkinci ve Üçüncü Aşama (Diyabetik Retinopati ve Çoklu Hastalık Tespiti):**

Bu çalışmanın ikinci aşamasında, Indian Diabetic Retinopathy Image Dataset (IDRİD) adlı açık erişimli retinal fundus görüntüleri veri seti kullanılmıştır. IDRİD, diyabetik retinopati (DR) ve makula ödemi (ME) tanısı için kullanılan, her görüntü için hastalık şiddeti ve makula ödemi bilgisi sağlayan bir tıbbi görüntüleme veri setidir.

Veri seti iki gruptan oluşmaktadır:

- Diyabetik Retinopati (DR) hastalarına ait retinal görüntüler
- Normal bireylere ait retinal görüntüler

Her görüntü 512x512 boyutunda olup, üç kanallı (RGB) formatındadır.

Eğitim ve test verisi olarak: Normal şeklinde etiketlenmiş toplam 300 görüntü (Eğitim: 100 DR + 100 Normal /Test: 50 DR + 50 Normal) kullanılmıştır. Bu veriseti kullanılarak görüntülerin diyabetik retinopatisi olan hasta bireye mi yoksa normal bireye mi ait olduğu tespit edilmeye çalışılmıştır. Bu aşama bittikten sonra Kaggle'dan alınan veriseti kullanılarak üçüncü aşamaya geçilmiştir. Alınan veri setinde diyabetik retinopati, katarakt, glokom ve normal olmak üzere dört sınıf bulunmaktadır. Bu aşamada ise klasik makine öğrenmesinin aksine derin öğrenme kullanılarak hastalık tespiti yapacak en iyi modeli bulmak ve optimizasyon yaparak en yüksek başarının alınması amaçlanmıştır.

Görüntü İşleme Teknikleri

Fundus görüntüleri üzerinde çeşitli görüntü işleme teknikleri uygulanarak görüntü kalitesinin artırılması, gürültünün azaltılması ve önemli yapıların belirginleştirilmesi amaçlanmıştır. Kullanılan temel görüntü işleme adımları ve teknikleri şunlardır:

İlk Aşama (Glokom Tespiti) İçin Uygulanan Görüntü İşleme Teknikleri:

- **Ön İşleme:**

- Gri tonlama, renk bilgisi yerine yalnızca parlaklık bilgisini tutar, bu da aydınlatma problemleriyle daha etkili başa çıkmamızı sağlar. Bunun için Renkli (BGR) fundus görüntüleri, aydınlatma sorunlarını gidermek amacıyla gri tonlamaya dönüştürülmüştür.


- Gri tonlamalı görüntüler üzerinde morfolojik açılma (morphological opening) tekniği uygulanarak arka plan tahmini yapılmış ve orijinal görüntüden çıkarılarak dc seviyesi eklenmiştir.

- **Damar Yapılarının Belirginleştirilmesi ve Çıkarılması:**


- Gri tonlamalı görüntülerin kontrastı, Kontrast Sınırlı Adaptif Histogram Eşitleme (CLAHE) tekniği ile artırılmıştır. CLAHE, görüntüdeki düşük kontrastlı alanları iyileştirerek daha keskin ve net görseller oluşturur
- Damarları tespit etmek için morfolojik gradient işlemi uygulanmıştır. Bu işlem damarların kenarlarını belirginleştirir ve ince yapıları ortaya çıkarır
- Eşikleme (thresholding) işlemi ile damarların bulunduğu alanlar belirlenerek bir maske oluşturulmuştur. Damarların bulunduğu alanları beyaz ile işaretler ve maskeyi oluşturur.
- Bulunan kan damarlarını görüntüden kaldırmak için inpainting (yeniden boyama) yöntemi kullanılmıştır. Inpainting, kaybolan veya istenmeyen öğelerin yerine çevresindeki piksel bilgilerini kullanarak tahmin edilen değerlerin yerleştirilmesi işlemidir.

- **Optik Disk ve Cup Tespiti:**


- Optik disk ve cup bölgelerini tespit etmek için Multi-thresholding tekniği kullanılmıştır. Bu teknik, farklı eşik değerleri kullanarak her iki yapıyı bağımsız olarak segment etmeyi amaçlamıştır. Bu, göz hastalıklarını teşhis etmek ve göz sağlığını izlemek için yararlı bir tekniktir



Şekil1




Şekil2



Şekil3

Şekil1: Glokom Hastalığına Ait Örnek Fundus Görseli Şekil2) Illumination Correction Uygulanmış Görseli Şekil3) Kan Damarları Çıkarılmış Görseli.

Multi-Thresholding Yöntemi Sonuçları:



Şekil4: Disk Bölgesi



Şekil5: Cup Bölgesi


İkinci Aşama (Diyabetik Retinopati Tespiti ve Segmentasyonu) İçin Uygulanan Yöntemler:

Yapılacak ilk segmentasyon optik diskin segmentasyonudur. Optik Disk (OD), gözün yüksek yoğunluklu bölgesidir ve OD bölgesinin tanımlanması, hastalıkların analizi için bölgeden kaçınılabileceğimiz için en önemli görevdir. Optik diskin segmentasyonu, bazı kanamaların boyut ve renk olarak optik diske çok benzemesi nedeniyle kırmızı lezyonların tespitinde önemli bir rol oynar. Dolayısıyla, retinadaki diyabetik etkilenen kısımları belirleyebilmek ve sonunda kişinin diyabetten etkilendiği sonucuna varabilmek için optik diski maskelememiz gerekir.

- **Optik Disk Segmentasyonu:** Optik disk çevresindeki lezyonların analizini kolaylaştırmak amacıyla doğru bir şekilde maskelenmesi hedeflenmiştir.

Bu amaçla aşağıdaki adımlar izlenmiştir:

- Görüntü, sabit bir boyuta yeniden boyutlandırılmıştır. Bu işlem, görüntüyü sabit bir boyuta ölçeklendirerek daha hızlı ve verimli işlem yapılmasını sağlar
- Optik diskin daha belirgin olduğu kırmızı kanal seçilmiştir. Retina görüntülerinde, optik disk kırmızı kanalda diğer kanallara göre daha belirgin olduğu için bu kanal tercih edilmiştir.
- Kırmızı kanalın kontrastı CLAHE (Contrast Limited Adaptive Histogram Equalization) ile artırılmıştır. Bu işlem, düşük kontrastlı alanlarda detayları vurgulayarak optik diski daha görünür hale getirir.
- Görüntünün parlaklık değerleri normalize edilmiştir. Bu, piksel değerlerini tutarlı bir aralığa getirerek segmentasyon sonuçlarını daha güvenilir hale getirir
- K-means kümeleme algoritması kullanılarak en parlak küme optik disk olarak belirlenmiştir.
- Morfolojik açma ve kapama işlemleriyle maskenin doğruluğu artırılmış ve küçük gürültüler temizlenmiştir. Açma işlemi ile küçük gürültüler temizlenirken, kapatma işlemi boşlukları doldurarak maskenin bütünlüğünü sağlamıştır. Bu işlemler, optik diskin daha düzgün ve net bir şekilde izole edilmesini sağlar.
- Optik diskin dairesel şeklini yakalamak için en büyük konturun etrafında bir çevreleyen daire oluşturulmuştur. Dairenin kenarları Gaussian bulanıklığı ile yumuşatılmıştır. Bu adım, maskenin daha pürüzsüz görünmesini ve küçük hataların giderilmesini sağlar.
- Son olarak maske genişletilerek optik diski tamamen kapsayan bir yapı elde edilmiş ve optik diski çevreleyen diğer yapılarla karışmasını önlemek için görüntüden çıkarılmıştır.




Şema 1 Optik disk segmentasyonu için iş akışı

Optik diskin segmentasyonu yapıldıktan sonra kan damarlarının çıkarılması gerekir. Diyabetik retinopati, retinadaki küçük kan damarlarının hasar görmesiyle ortaya çıkar. Bu hasar, kanamalar, mikroanevrizmalar, damar genişlemeleri veya yeni anormal damar oluşumları gibi değişikliklere neden olabilir. Kan damarlarının çıkarılması, bu tür anormalliklerin daha net bir şekilde görülmesini sağlar.

- **Kan Damarlarının Çıkarılması:**

Diyabetik retinopati teşhisinde önemli olan anormal damar yapılarını daha net analiz edebilmek amacıyla kan damarlarının görüntüden çıkarılması için aşağıdaki adımlar uygulanmıştır:

- Giriş görüntüsü sabit bir çözünürlüğe ölçeklendirilmiştir.
- Retina damarlarının daha belirgin olduğu yeşil kanal seçilmiştir.
- Yeşil kanalın kontrastı CLAHE ile iyileştirilmiştir. Kontrast iyileştirme işlemi, damarların arka plandan net bir şekilde ayrılmasını sağlar.
- İki ayrı işlem hattı kullanılmıştır:
 - İlk Hat: Medyan bulanıklaştırma uygulanarak gürültü azaltılmış ve bulanıklaştırılmış görüntü orijinal görüntüden çıkarılarak damarlar belirginleştirilmiştir. Bu sonuç eşiklenerek ikili bir görüntü elde edilmiş ve morfolojik işlemlerle gürültü temizlenmiştir.
 - İkinci Hat: Benzer adımlar farklı bir yaklaşımla uygulanarak bir sonuç elde edilmiştir.
- İki işlem hattının sonuçları bit düzeyinde birleştirilerek her iki yöntemin avantajları bir araya getirilmiştir.
- Birleştirilmiş görüntü orijinal çözünürlüğe yeniden boyutlandırılarak giriş görüntüsüyle aynı çözünürlüğe getirilir.



Şema 2 Kan Damarlarının Segmentasyonu İçin İş Akışı

Mikroanevrizma, diyabetik retinopatinin erken evrelerinde görülen ilk değişikliklerdendir, retinadaki küçük kan damarlarının (kapillerlerin) duvarında meydana gelen zayıflama sonucu oluşan baloncuk benzeri şişliklerdir. Bu şişlikler, kan damarlarının genişlemesi veya çıkıntı yapması şeklinde gözlenir ve genellikle retina üzerinde kırmızı nokta şeklinde görünürler.


Mikroanovrizmaların segmentasyonu, mikroanevrizmaların konumunu ve sayısını belirleyerek hastalığın teşhisinde yardımcı olur. Hastalığın hangi evrede olduğunu anlamaya yardımcı olur.

- **Mikroanevrizma Segmentasyonu:**

Diyabetik retinopatinin erken belirtilerinden olan mikroanevrizmaların tespiti için aşağıdaki adımlar izlenmiştir:

- Görüntü, kırmızı, yeşil ve mavi kanallarına ayrılmış ve mikroanevrizmaların daha belirgin olduğu düşünülen yeşil kanal ters çevrilmiştir. Bu kanal ters çevrilerek ilgi alanlarının vurgulanması hedeflenir
- Yerel kontrastı artırmak için CLAHE uygulanmıştır. Bu işlem, mikroanevrizmaların daha görünür hale gelmesine yardımcı olur.
- Parlaklık ve kontrastı iyileştirmek için gamma ayarları yapılmıştır. Bu adımlarla parlaklık ve kontrast daha da iyileştirilir, böylece mikroanevrizmalar daha net bir şekilde öne çıkar.

- Gürültüyü azaltmak için Gaussian filtresi ile yumuşatma uygulanmıştır. ve gereksiz küçük detaylar giderilmiştir.
- Otsu eşikleme ile görüntü siyah-beyaz formata dönüştürülmüştür. Bu, mikroanevrizmaların bulunduğu bölgeleri daha belirgin hale getirir
- Top Hat dönüşümü ile parlak alanlar öne çıkarılmış ve morfolojik açma işlemi ile küçük gürültüler temizlenerek mikroanevrizmaların yer aldığı bir ikili görüntü elde edilmiştir.



Şema 3 Mikroanevrizmaların Segmentasyonu İçin İş Akışı


Eksuda (eksudatlar), diyabetik retinopati (DR) tespitinde önemli bir biyolojik göstergedir. Eksudalar, genellikle sert eksuda olarak adlandırılan sarımsı beyaz, parlak ve keskin sınırlı lezyonlardır. Bu yapıların oluşumu, retinadaki kan damarlarının geçirgenliğinin artması sonucu ortaya çıkan sıvı ve lipid sızıntısına bağlıdır.

Eksudaların boyutu, sayısı ve yerleşim alanı, diyabetik retinopatinin şiddetini değerlendirmek için kullanılabilir.


- **Eksüda Segmentasyonu:**

Diyabetik retinopati teşhisinde önemli bir diğer gösterge olan eksüdaların segmentasyonu için aşağıdaki adımlar uygulanmıştır:


- Görüntüler standart bir boyuta yeniden boyutlandırılmıştır.
- Damar ve eksüdaların daha belirgin olduğu yeşil kanal seçilmiştir.
- Büyük eksüdaların segmentasyonu için K-means kümeleme algoritması kullanılarak bir maske oluşturulmuştur. Bu işlem sırasında, görüntü sekiz kümeye ayrılır ve belirli parametrelerle büyük exudatları içeren bir maske oluşturulur.
- Küçük eksüdaların tespiti için Canny kenar tespiti uygulanmış, kenarlar morfolojik işlemlerle genişletilmiş, kontur analizi yapılarak küçük exudatlar belirgin hale getirilirmiş ve ve yoğunluk eşikleme ile ikili bir maske oluşturulmuştur.
- Büyük ve küçük eksüda maskeleri birleştirilerek nihai eksüda maskesi elde edilmiştir.
- Optik disk ile karışıklığı önlemek için önceden işaretlenmiş optik disk maskesi kullanılarak bu bölge çıkarılmıştır.
- Son olarak, orijinal görüntü ve segmentasyon sonuçları görselleştirilmiştir.



Şema 4 Exudaların Segmentasyonu İçin İş Akışı




Şekil5:Optik Disk Segmentasyon Sonucu



Şekil6: Kan damarlarının çıkarılması



Şekil7:Mikroanovrizmaların çıkarılması



Şekil 9:exudatların çıkarılması

• Öznitelik Çıkarımı

Diyabetik retinopati hastalığının tespiti için görüntü işleme adımları tamamlandıktan sonra elde edilen segmentasyonlu sonuçlardan (optik disk, kan damarları, mikroanevrizmalar, eksüdalar) öznitelikler çıkarılması için çalışmalara başlanmıştır. Bunun için öncelikli olarak belirlenen veriseti üzerinden train için 100 hasta 100 normal görüntü, test için 50 hasta 50 normal görüntü ayarlanmıştır. Bu görüntülerin segmentli görselleri kaydedildikten sonra segmentli sonuçlardan gerekli istatistiksel öznitelikler çıkarıldı daha sonra oluşturulan yeni veri seti makine öğrenmesi modellerine verilerek en yüksek başarıyı alan model tespit edilmiştir.

- Segmentasyon sonuçlarından aşağıdaki temel öznitelikler çıkarılmıştır:
 - Alan (beyaz piksellerin toplamı)
 - Ortalama piksel değeri
 - Piksel yoğunluğunun standart sapması
 - Doluluk oranı (segmentli bölgenin görüntüye oranı)

Hastalıklı olan görsellerde özellikle kan damarları ve eksüda ile yorumlandığında, optik disk alanın

normalden büyük olması modelin DR sınıfına yönelmesine sebep olabilir. Dolayısıyla Optik diskin segmentasyon işleminden elde edilen ikili (binary) görüntü üzerinde, optik diski temsil eden beyaz piksellerin (255 değerindeki piksellerin) sayısını belirleyerek bu yapının görüntü üzerindeki kapladığı alanı hesaplama işlemi yapılır. Mikroanevrizmalar, diyabetik retinopatinin ilk ve en belirgin klinik bulgularıdır. Dolayısıyla tüm görüntü üzerinde doluluk oranı arttıkça DR'ye sahip olma olasılığı artar. Mikroanevrizmaların segmentasyonlu sonucundan elde edilen görüntü üzerinde mikroanevrizmaların kapladığı oransal alan hesaplanmıştır. Kan damarlarının segmentasyonlu sonucundan elde edilen görüntü üzerinde kan damarlarının uzunluğu ve kıvrımlılığı hesaplanmıştır. Çünkü DR ye sahip olunan kişilerde anormal damar büyümeleri meydana gelmektedir. Bu durum damar ağının büyümesine neden olur. Ayırtıyeten DR'nin ilerlemiş evrelerinde damarlar daha düzensiz, kıvrımlı ve kaotik hale gelir. Normal bireylerde damarlar genellikle daha düz ve düzenlidir; kıvrıklık oranı düşüktür. Dolayısıyla bu iki öznelik hastalık belirlemede önemli belirteçlerdir. Bunun için öncelikle iskelet hattı çıkarılmış daha sonra bu iskelet üzerindeki tüm beyaz pikseller toplanarak toplam damar uzunluğu bulunmuştur. Bulunan iskelet üzerinden konturlar belirlenerek bulunan konturların çevresi hesaplanmış son olarak çevre uzunluğu ile toplam damar uzunluğu oranlanarak kıvrıklık derecesi hesaplanmıştır. DR hastalığında, eksüda, mikroanevrizma, kanama gibi yüksek kontrastlı yapılar oluşur. Bu anomaliler görüntüde daha fazla kenar bilgisi üretir. Bu nedenle kenar yoğunluğu DR'li bireylerde genellikle daha yüksektir. Normal görüntüler daha homojen olduğu için kenar yoğunluğu daha düşüktür. DR'li gözlerde görüntü daha heterojen olur: parlak eksüdalar, koyu kanamalar, normal doku karışır. Bu da yoğunluk standart sapmasını artırır. Normal gözlerde ise daha homojen yapı olduğundan bu değer düşüktür. Bu yüzden standart sapma hesaplanır.

- Her bir görüntü için 4 farklı segmentasyondan toplam 8 öznelik çıkarılmış ve bu öznelikler train_features.csv ve test_features.csv dosyalarına kaydedilmiştir.

	image_name	class	Optic Disc Area	MA Ratio	Vessel Length	Vessel Tortuosity	Edge_Density	Mean_Intensity	Std_Deviation	Exudate_Density
0	IDRID_001.jpg	1	18861	0.000339	60345	1.352784	0.019490	71.999626	48.732911	0.033892
1	IDRID_002.jpg	1	23420	0.000180	51485	1.476808	0.018572	70.925728	47.566503	0.005241
2	IDRID_003.jpg	1	8984	0.000010	29652	1.548771	0.002163	53.298688	37.172219	0.013723
3	IDRID_004.jpg	1	50125	0.000252	46040	1.528544	0.021770	63.372044	46.031325	0.010054
4	IDRID_005.jpg	1	4406	0.000572	44863	1.545336	0.021906	72.531829	48.698143	0.023145
...	...	...	...	...	...	...	...	...	...	...
195	IDRID_196.jpg	0	22340	0.000725	77501	1.108138	0.043206	75.480133	54.146752	0.027006
196	IDRID_197.jpg	0	30319	0.000476	67631	1.421064	0.041663	69.869558	50.659041	0.021470
197	IDRID_198.jpg	0	9629	0.000326	56541	1.466966	0.034047	51.793618	40.690632	0.010018
198	IDRID_199.jpg	0	29101	0.000681	73863	1.186056	0.034319	73.821505	53.282892	0.002976
199	IDRID_200.jpg	0	20765	0.000633	82749	1.178592	0.049796	74.912342	54.090461	0.021241

200 rows x 10 columns

Tablo1: Train_features.csv tablosu

	image_name	class	Optic Disc Area	MA Ratio	Vessel Length	Vessel Tortuosity	Edge_Density	Mean_Intensity	Std_Deviation	Exudate_Density
0	IDRiD_001.jpg	1	0	0.000012	16082	1.583643	0.000809	27.543258	19.713929	0.001229
1	IDRiD_002.jpg	1	1874	0.000054	26054	1.568621	0.004242	41.831461	31.072523	0.003030
2	IDRiD_003.jpg	1	0	0.000066	29084	1.573119	0.007770	52.665440	36.961635	0.027271
3	IDRiD_004.jpg	1	2673	0.000543	69367	1.454656	0.036408	65.251439	47.482030	0.102217
4	IDRiD_005.jpg	1	0	0.000015	18622	1.583566	0.013398	42.553625	33.469694	0.017422
...	...	...	...	...	...	...	...	...	...	...
95	IDRiD_097.jpg	0	26219	0.001297	65663	1.452875	0.011241	95.923727	64.257926	0.027663
96	IDRiD_098.jpg	0	0	0.000190	37739	1.580730	0.014241	40.783005	30.689003	0.001651
97	IDRiD_099.jpg	0	10286	0.000460	55865	1.342510	0.014170	75.070309	49.371682	0.002747
98	IDRiD_100.jpg	0	16414	0.000421	51854	1.540237	0.018266	74.273027	48.489168	0.000000
99	IDRiD_51.jpg	0	26865	0.000629	62574	1.344867	0.001031	67.050318	45.261249	0.001530

100 rows x 10 columns

Tablo2: Test_features.csv tablosu

• Sınıflandırma ve Değerlendirme

- Standard Scaler ile özellikler normalize edilmiştir. Bu işlem, verinin ortalamasını 0, standart sapmasını 1 yaparak algoritmaların daha kararlı çalışmasını sağlar.
- Öznitelikler kullanılarak çeşitli makine öğrenmesi algoritmaları ile sınıflandırma yapılmıştır:
 - Random Forest
 - Support Vector Machines (SVM)
 - Logistic Regression
 - K-Nearest Neighbors (KNN)
- Modellerin başarımı şu metriklerle değerlendirilmiştir:
 - Doğruluk (Accuracy)
 - Precision
 - F1-Score
 - Confusion Matrix

Yapılan çalışmalar sonucunda karşılaştırmalı sonuç aşağıda verilmiştir :

	Model	Accuracy	F1 Score	recall
0	Logistic Regression	0.64	0.69	0.82
1	Random Forest	0.69	0.71	0.76
2	SVM	0.64	0.65	0.68
3	KNN	0.63	0.68	0.78

Tablo3: Karşılaştırmalı sonuç tablosu

- En iyi sonucu veren modelin random forest olduğu sonucuna varılmıştır.

Random Forest, birden fazla karar ağacının birleştirilmesiyle oluşturulan, yüksek doğruluk oranına sahip, esnek ve aşırı öğrenmeye karşı dayanıklı bir topluluk (ensemble) algoritmasıdır. Bu çalışmada sınıflandırma problemi için tercih edilmiştir.


Random Forest algoritmasının performansını etkileyen çeşitli hiperparametreler bulunmaktadır. Bu

parametrelerin en uygun kombinasyonunu bulmak amacıyla GridSearchCV yöntemi kullanılmıştır. GridSearchCV, bu parametrelerin tüm kombinasyonlarını deneyerek her biri için 5 katlı çapraz doğrulama (5-fold CV) uygulamış ve en iyi sonuç veren modeli seçmiştir.

- En iyi parametre kombinasyonu elde edildikten sonra, model test veri seti üzerinde değerlendirilmiştir. Sonuçlar aşağıdaki gibidir.

Classification Report:				
	precision	recall	f1-score	support
0	0.72	0.62	0.67	50
1	0.67	0.76	0.71	50
accuracy			0.69	100
macro avg	0.69	0.69	0.69	100
weighted avg	0.69	0.69	0.69	100

Tablo 4: Random forest sonuç tablosu



Şekil 10: Random Forest konfüzyon matris görseli

Üçüncü Aşama (Derin Öğrenme ile Çoklu Hastalık Sınıflandırması):

Bu aşamada, Diyabetik Retinopati, Katarakt, Glokom ve Normal olmak üzere dört farklı göz hastalığının fundus görüntülerinden otomatik olarak teşhis edilmesi amacıyla derin öğrenme modelleri geliştirilmiştir. Projenin bu bölümünde kullanılan yöntemler ve adımlar aşağıda detaylandırılmıştır:

- **Veri Seti Hazırlığı ve Etiketleme:**
 - Kaggle platformundan alınan veri seti kullanılarak, Diyabetik Retinopati, Katarakt, Glokom ve Normal olmak üzere dört farklı sınıf tanımlanmıştır.

- Tüm görüntüler, her bir alt klasörün bir sınıfı temsil edecek şekilde organize edilerek dataset/ klasörünün altına yerleştirilmiştir.
- **Görüntü Ön İşleme ve Veri Artırma:**
 - Diskten okunan retina görüntüleri, PIL (Python Imaging Library) kütüphanesi kullanılarak üç kanallı RGB (Kırmızı, Yeşil, Mavi) formata dönüştürülmüştür.
 - Modellerin sabit giriş boyutu gereksinimlerini karşılamak amacıyla tüm görüntüler 224x224 piksel boyutuna ölçeklenmiştir.
 - Eğitim sırasında aşırı öğrenmeyi (overfitting) azaltmak ve modelin farklı çekim koşullarına karşı genelleme yeteneğini güçlendirmek için torchvision.transforms modülü aracılığıyla bir dizi rastgele dönüşüm uygulanmıştır. Bu dönüşümler şunları içermektedir:
 - Yatay ve dikey ekseninde %50 olasılıkla çevirme.
 - $\pm 15^\circ$ arası rastgele döndürme.
 - Parlaklık, kontrast ve doygunlukta %20'ye kadar rastgele renk oynatımı.
 - Tüm bu ön işleme adımlarının ardından görüntüler PyTorch tensörlerine dönüştürülmüş ve piksel değerleri [0,1] aralığına ölçeklenerek optimizasyon sürecinin stabil kalması sağlanmıştır.
 - Doğrulama (validation) ve test setlerinde ise yalnızca yeniden boyutlandırma ve tensöre dönüştürme işlemleri uygulanmıştır. Bu, model performansının eğitimde görülmeyen ancak gerçek dünya koşullarına yakın bir dağılım üzerinden ölçülmesini hedeflemiştir.
- **Veri Setinin Bölünmesi:**
 - Veri seti, modelin genelleme yeteneğini güvenilir biçimde değerlendirebilmek amacıyla iki aşamalı stratifiye bölme yöntemiyle ayrılmıştır. Bu yöntem, her sınıfın veri setindeki oranının eğitim, doğrulama ve test kümelerinde de korunmasını sağlamıştır.
 - İlk aşamada, tüm örneklerin %20'si test kümesi olarak ayrılmıştır. Sınıf dağılımının korunması için stratify parametresi kullanılmış ve sonuçların tekrarlanabilirliği için random_state=28 sabit bir rastgele değerle sabitlenmıştır.
 - İkinci aşamada, elde kalan %80'lik alt küme üzerinde bir bölme daha uygulanarak, bu alt kümenin %12.5'i doğrulama (validation) kümesine tahsis edilmiştir. Bu düzenleme sonucunda, orijinal veri seti sırasıyla %70 eğitim, %10 doğrulama ve %20 test örneklerinden oluşacak şekilde düzenlenmiştir.
 - Her bir alt küme, önceden tanımlanmış dönüşüm (transform) zincirlerini uygulayan EyeDataset sınıfına sarılmıştır (eğitim için train_transform, doğrulama ve test için val_transform kullanılmıştır).
 - Model eğitimi sırasında kullanılacak sınıf sayısı 4 olarak tanımlanmış ve her iterasyonda işlenecek örnek sayısını belirleyen mini-batch büyüklüğü ayarlanmıştır.
 - Veri yükleme işlemleri, PyTorch'un DataLoader yapısı aracılığıyla gerçekleştirilmiştir. Eğitim

verisini besleyen DataLoader, her epoch başında örneklerin karıştırılmasını (shuffle=True) sağlayarak modelin ardışık örnek ilişkilerine aşırı bağımlı hale gelmesini engellerken; doğrulama ve test DataLoader'ları, deterministik bir değerlendirme süreci için karıştırma işlemi uygulanmaksızın (shuffle=False) yapılandırılmıştır. Bu düzenleme, GPU hızlandırılmalı eğitim döngüleriyle uyumlu, verimli ve tekrarlanabilir bir eğitim-değerlendirme altyapısı sunmuştur.

- **Modelleme ve Performans Değerlendirmesi:**

- Çalışmada, ImageNet üzerinde ön-eğitilmiş beş farklı konvolüsyonel sinir ağı (CNN) mimarisi, dört sınıflı retina görüntü sınıflandırma görevine transfer öğrenme yaklaşımıyla uyarlanmıştır. Transfer öğrenme, başka bir görev için eğitilmiş bir modelin yeni bir görevde yeniden kullanılması prensibine dayanır ve özellikle sınırlı veri bulunan durumlarda büyük avantaj sağlar. Kullanılan mimariler şunlardır:
 - **ResNet-18**
 - **DenseNet-121**
 - **MobileNetV2**
 - **EfficientNet-B0**
 - **EfficientNet-B3**
- Her bir mimari için eğitim sürecinin performansını maksimize etmek amacıyla ince-ayar (fine-tuning) çalışmaları yürütülmüştür. Optimize edilen hiperparametreler arasında mini-batch büyüklüğü (Batch Size), optimizatör tipi (Optimizer), dondurulan katman sayısı (Frozen Layers), başlangıç öğrenme oranı (Learning Rate) ve erken durdurma sabrı (Patience) bulunmaktadır. En iyi kombinasyonlar manuel deneme-yanılma yöntemleriyle belirlenmiştir. her modelin nihai konfigürasyonu Tablo 8'de sunulmuştur.

Model Adı	Batch Size	Optimizer	Dondurulan Katman Sayısı	Learning Rate	Dropout	Patience
Resnet18	32	AdamW	Son 50	1e-5,8e-4	0.5	3
MobilnetV2	32	Adam	Son 50	3e-5,8e-4	0.5	5
EfficientB0	32	AdamW	Son 50	3e-5,5e-4	0.5	3
EfficientB3	64	Adam	Son 25	3e-5,5e-4	0.5	3
Densenet121	64	AdamW	Son 25	3e-5,8e-4	0.5	3

Tablo 5: Hiperparametre optimizasyon tablosu

Tablodaki değerler, her model için validation ve test kümesi üzerindeki doğruluk ve F1 metriklerinin en yüksek olduğu ayarları göstermektedir. Bu sayede, mimarilerin yapısal farklılıklarına bağlı öğrenme dinamikleri göz önünde bulundurularak her bir ağ için en uygun eğitim stratejisi uygulanmıştır. Modellerin ayrıntılı sonuçları ve grafikler aşağıda verilmiştir.

➤ RESNET18


```

Train - Loss: 0.1813 | Acc: 0.9366 | F1: 0.9355
Validate - Loss: 0.1732 | Acc: 0.9336 | F1: 0.9327
Early stopping triggered.
Val: 100%|██████████| 27/27 [00:10<00:00, 2.47it/s]


=== Test Seti Sonuçları ===
Test - Loss: 0.2275 | Acc: 0.9111 | F1: 0.9102

```

Şekil11: ResNet18 Modelinin Eğitim, Doğrulama ve Test Seti Performans Metrikleri



Şekil12: Resnet18 Modelinin kayıp ve doğrulama grafikleri



Şekil13: Resnet18 modelinin karmaşıklık matrisi


➤ MOBİLENETV2

```


Train - Loss: 0.2255 | Acc: 0.9153 | F1: 0.9141
Validate - Loss: 0.2312 | Acc: 0.9123 | F1: 0.9103
Early stopping triggered.
Val: 100%|██████████| 27/27 [00:11<00:00, 2.28it/s]

=== Test Seti Sonuçları ===
Test - Loss: 0.2116 | Acc: 0.9159 | F1: 0.9142
    
```

Şekil14: ResNet18 Modelinin Eğitim, Doğrulama ve Test Seti Performans Metrikleri



Şekil15: Mobilenetv2 Modelinin kayıp ve doğrulama grafikleri



Şekil16: Mobilenetv2 modelinin karmaşıklık matrisi


➤ EFFICIENTB0

```
Train - Loss: 0.2391 | Acc: 0.9112 | F1: 0.9102
Validate - Loss: 0.2424 | Acc: 0.9028 | F1: 0.9019
Val: 100%|██████████| 27/27 [00:12<00:00, 2.13it/s]
```


=== Test Seti Sonuçları ===

```
Test - Loss: 0.2240 | Acc: 0.9171 | F1: 0.9151|
```

Şekil17: Efficientb0 Modelinin Eğitim, Doğrulama ve Test Seti Performans Metrikleri



Şekil18: Efficientb0 Modelinin kayıp ve doğrulama grafikleri



Şekil19: Efficientb0 modelinin karmaşıklık matrisi


➤ EFFICIENTB3

```


Train - Loss: 0.3767 | Acc: 0.8567 | F1: 0.8565
Validate - Loss: 0.3098 | Acc: 0.9147 | F1: 0.9135
Val: 100%|██████████| 14/14 [00:13<00:00, 1.01it/s]

=== Test Seti Sonuçları ===
Test - Loss: 1.2524 | Acc: 0.8827 | F1: 0.8805
    
```

Şekil20: Efficientb3 Modelinin Eğitim, Doğrulama ve Test Seti Performans Metrikleri



Şekil21: Efficientb3 Modelinin kayıp ve doğrulama grafikleri



Şekil22: Efficientb3 modelinin karmaşıklık matrisi

➤ DENSENET121


```

Train - Loss: 0.2233 | Acc: 0.9105 | F1: 0.9091
Validate - Loss: 0.3049 | Acc: 0.9028 | F1: 0.9027
Val: 100%|██████████| 14/14 [00:14<00:00, 1.01s/it]


=== Test Seti Sonuçları ===
Test - Loss: 0.2405 | Acc: 0.9052 | F1: 0.9026

```

Şekil23: DenseNet121 Modelinin Eğitim, Doğrulama ve Test Seti Performans Metrikleri



Şekil24:DenseNet121 Modelinin kayıp ve doğrulama grafikleri



Şekil25:DenseNet121 modelinin karmaşıklık matrisi

Daha sonra aynı veriseti üzerinde yapılan çalışmalarla kıyaslama yapılmış. Bu karşılaştırma Tablo 9 da sunulmuştur.

Çalışma	Yıl	Kullanılan Model	Veri Seti	Accurac y	Benim Sonuçlarım	Not (Veri Seti Ayrımı)
Sheetal J. Nagar, Nikhil Gondaliya	2025	Resnet18	Eye Diseases Classificati on Dataset	%93.30	Accuracy: %93.36 Test Acc: %93.02	70:30/ 70:10:20
Sheetal J. Nagar, Nikhil Gondaliya	2025	MobileNet	Eye Diseases Classificati on Dataset	%95.67	Accuracy: %90.20 Test Acc: %91.67	70:30/ 70:10:20 /
Sheetal J. Nagar, Nikhil Gondaliya	2025	DenseNet121	Eye Diseases Classificati on Dataset	%93.99	Accuracy: %90.28 Test Acc: %90.52	70:30/ 70:10:20
Sheetal J. Nagar, Nikhil Gondaliya	2025	EfficientNetB3	Eye Diseases Classificati on Dataset	%95.97	Accuracy: %91.35 Test Acc: %88.05	70:30/ 70:10:20
Cahaya Jatmoko, Heru Lestiawan, Feri Agustina, Lalang Erawan	2024	MobileNet	Eye Diseases Classificati on Dataset	73.00%	Accuracy: %90.20 Test Acc: %91.67	70:10:20 / 70:10:20
Cahaya Jatmoko, Heru Lestiawan, Feri Agustina, Lalang Erawan	2024	DenseNet	Eye Diseases Classificati on Dataset	78.43%	Accuracy: %90.28 Test Acc: %90.52	70:10:20 / 70:10:20

Cahaya Jatmoko, Heru Lestiawan, Feri Agustina, Lalang Erawan	2024	EfficientNetB3	Eye Diseases Classificati on Dataset	%95.66	Accuracy: %91.35 Test Acc: %88.05	70:10:20 / 70:10:20
K.Babski- Reeves, B.Eksioglu, D.Hampton	2023	EfficientNet	Eye Diseases Classificati on Dataset	%94	Accuracy: %90.28 Test Acc: %91.70	70:10:20 / 70:10:20

Tablo6:Karşılaştırmalı tablo

- Çalışmanın bu kısmında, retina görüntülerinden göz hastalıklarının otomatik olarak teşhis edilmesi amacıyla derin öğrenme modelleri incelenmiş ve bu modellerin performansları karşılaştırılmıştır.
- Modellerin ayrıntılı sonuçları ve grafikler sunularak, özellikle ResNet-18 modelinin en yüksek doğruluğa ve genelleme yeteneğine sahip olduğu gözlemlenmiştir. Bu sonuçlar, her model için doğrulama ve test kümesi üzerindeki doğruluk (Accuracy) ve F1 metriklerinin en yüksek olduğu ayarları yansıtmaktadır.

• Ek Özellik Çıkarımı ve Sınıflandırma Yöntemleri

Projenin devamında, en yüksek başarıyı veren ResNet-18 modeli üzerinde özellik indirgeme teknikleri uygulanmıştır. Derin öğrenme modelleriyle genel sınıflandırma çalışmalarının yanı sıra, önceden eğitilmiş ResNet18 modelinden elde edilen görsel özellikler üzerinde ileri seviye analizler ve farklı sınıflandırma yaklaşımları denenmiştir. Bu yaklaşım, modelin öğrenmiş olduğu yüksek seviyeli özellikleri daha iyi anlamak ve potansiyel olarak daha yorumlanabilir veya daha verimli bir sınıflandırma süreci oluşturmak amacıyla gerçekleştirilmiştir.

○ ResNet18'den Özellik Çıkarımı

Öncelikle, Kaggle veri seti üzerinde eğitilmiş ve başarıyla yüklendiği teyit edilen ResNet18 modelinin özellik çıkarıcı (feature extractor) katmanları kullanılmıştır. Bu, modelin son sınıflandırma katmanı (classifier) öncesindeki bölümünü ifade eder ve modelin görüntülerden öğrenmiş olduğu zengin görsel temsilleri (özellik vektörlerini) elde etmemizi sağlar. Bu özellik vektörleri, orijinal piksel değerlerinden çok daha anlamlı ve yüksek seviyeli bilgiler içerir.

Bu süreçte, eğitim ve test veri setlerindeki tüm görüntüler sırasıyla işlenmiştir. Her bir görüntü için, ResNet18'in son evrişim katmanından çıkan özellik haritaları düzleştirilerek (flatten) tek boyutlu bir vektör haline getirilmiş ve bu özellik vektörleri depolanmıştır. Elde edilen özelliklerin boyutları, modelin öğrenme kapasitesinin genişliğini göstermiştir. Ayrıca, ReliefF gibi bazı algoritmaların negatif değerlerle iyi çalışmaması nedeniyle, çıkarılan özellikler MinMaxScaler kullanılarak [0,1] aralığına normalize

edilmiştir.

○ **Boyut İndirgeme ve Yeni Sınıflandırıcı ile Sınıflandırma**

Çıkarılan yüksek boyutlu özellik vektörleri üzerinde iki farklı boyut indirgeme ve öznitelik seçimi yöntemi denenmiştir:

➤ **Temel Bileşen Analizi (PCA) ile Boyut İndirgeme**

Yüksek boyutlu özellik vektörlerinin işlenmesi, hem hesaplama maliyetini artırabilir hem de aşırı öğrenmeye neden olabilir. Bu sorunları gidermek amacıyla Temel Bileşen Analizi (PCA) kullanılarak boyut indirgeme yapılmıştır. PCA, orijinal veri kümesindeki varyansın büyük bir kısmını korurken, veri boyutunu azaltmaya olanak tanıyan güçlü bir istatistiksel yöntemdir.

Çalışmamızda, PCA $n_components=0.95$ parametresiyle uygulanmıştır. Bu, PCA'nın orijinal veri setindeki toplam varyansın %95'ini koruyacak en uygun bileşen sayısını otomatik olarak seçtiği anlamına gelir. Eğitim veri setinden elde edilen özellikler `pca.fit_transform()` ile dönüştürülmüş, test veri seti özellikleri ise `pca.transform()` kullanılarak aynı dönüşüm uygulanmıştır. Bu işlem sonucunda özellik vektörlerinin boyutu önemli ölçüde indirgenmiştir.

➤ **Relief Yöntemi ile Öznitelik Seçimi**

PCA'ya alternatif olarak ve daha ayırt edici öznitelikleri belirlemek amacıyla Relief öznitelik seçim algoritması uygulanmıştır. Relief, özniteliklerin sınıfları ayırt etme gücünü komşu örnekler arasındaki farklılıklara dayalı olarak değerlendiren bir yöntemdir. Özellikle çok sınıflı sınıflandırma problemlerinde ve etkileşimli özniteliklerin varlığında etkili olabilmektedir. Uygulamamızda, $n_neighbors=100$ ve $n_features_to_select=100$ parametreleri ile Relief kullanılmıştır. Bu, algoritmanın her örneğin 100 en yakın komşusunu dikkate alarak öznitelik ağırlıklarını hesapladığı ve en yüksek ağırlığa sahip 100 özniteliği seçtiği anlamına gelir. Seçilen bu öznitelikler, sınıflandırma performansını potansiyel olarak artırmak ve modelin karmaşıklığını azaltmak için kullanılmıştır.

○ **Boyut İndirgenmiş Özellikler Üzerinde Basit Sınıflandırıcılar ile Sınıflandırma**

Hem PCA hem de Relief ile boyutu indirgenmiş özellik vektörleri üzerinde basit bir tam bağlantılı (fully connected) sinir ağı modeli eğitilmiştir. Bu model, indirgenmiş özellik vektörlerini girdi olarak alıp dört farklı sınıf (diyabetik retinopati, katarakt, glokom, normal) arasında sınıflandırma yapmıştır.

Modelin yapısı, bir gizli katman ve bir çıkış katmanından oluşmaktadır:


- Bir doğrusal katman (indirgenmiş özellik boyutundan 128 nörona).
- Bir ReLU aktivasyon fonksiyonu.
- Bir dropout katmanı (aşırı öğrenmeyi engellemek için %50).
- Sınıf sayısına (4) eşit nöron sayısına sahip bir çıkış katmanı.

Her iki senaryoda (PCA ve Relief), model CrossEntropyLoss kriteri ve Adam optimizasyonu kullanılarak 10 epok boyunca eğitilmiştir. Eğitim süreci boyunca kayıp (loss) değerleri izlenmiştir. Eğitim tamamlandıktan sonra, boyut indirgenmiş test özelliklerini kullanarak modelin performansı değerlendirilmiştir.

Elde Edilen Sonuçlar:

Eğitim özelliklerinin şekli: (2951, 512)
 Test özelliklerinin şekli: (844, 512)
 PCA uygulanmış eğitim özelliklerinin şekli: (2951, 202)
 PCA uygulanmış test özelliklerinin şekli: (844, 202)


Şekil26: PCA Uygulaması Sonrasında Veri Boyutundaki Değişim



Şekil27:PCA ile elde edilen özelliklerin 2 boyutlu uzaydaki dağılımı ve karmaşıklık matrisi

Relieff ile seçilen eğitim özelliklerinin şekli: (2951, 100)
 Relieff ile seçilen test özelliklerinin şekli: (844, 100)

Şekil28: Relief Uygulaması Sonrasında Veri Boyutundaki Değişim



Şekil29:Relief Sonrası karmaşıklık matrisi

Orijinal Resnet-18 Başarısı	PCA Sonrası Başarı	Relief Sonrası Başarı
0.9336	0.9316	0.9325

Tablo7:Karşılaştırmalı tablo

Bu sonuçlar, hem PCA hem de Relief ile boyut indirgeme yapıldıktan sonra bile, elde edilen özelliklerin orijinal derin öğrenme modeline yakın bir sınıflandırma performansı sergileyebildiğini göstermektedir. Bu durum, hem hesaplama verimliliği açısından önemli bir avantaj sağlayabilir hem de modelin öğrenmiş olduğu kritik bilgilerin boyut indirgeme sonrasında büyük ölçüde korunduğunu işaret eder. Özellikle Relief'in benzer performans sergilemesi, bu yöntemin seçilen özelliklerin ayırt ediciliğini korumadaki başarısını vurgulamaktadır.

Her iki boyut indirgeme yaklaşımı da, yüksek boyutlu öz nitelik uzayını daha yönetilebilir bir boyuta indirgerken, sınıflandırma yeteneğinde önemli bir kayıp yaşanmadığını göstermiştir. Bu, derin öğrenme modellerinin ürettiği yüksek boyutlu özellik setlerinin, temel ayırt edici bilgileri taşıyan daha küçük bir alt kümesinin varlığını doğrular. Özellikle Relief, özelliklerin hedef değişkene göre önemini puanlayarak seçim yaptığı için, klinik olarak daha yorumlanabilir özelliklerin korunmasına yardımcı olabilir. Bu durum, modelin aldığı kararların arkasındaki nedenleri anlamak için potansiyel bir yol sunar ve tıbbi teşhis gibi kritik alanlarda şeffaflığı artırabilir.

Hesaplama Verimliliği ve Model Karmaşıklığı Üzerindeki Etkileri

Boyut indirgemenin getirdiği en somut avantajlardan biri hesaplama verimliliğidir. Özellik sayısının azaltılması, modellerin daha az parametre ile eğitilmesi anlamına gelir. Bu da eğitim süresini kısaltır, modelin depolama alanını azaltır ve çıkarım (tahmin) aşamasında daha hızlı yanıt süreleri sağlar. Özellikle mobil cihazlarda veya sınırlı kaynaklara sahip sistemlerde dağıtılacak uygulamalar için bu tür optimizasyonlar kritik öneme sahiptir. Projemizde Relief sonrası basit sınıflandırıcının, ResNet18 gibi karmaşık bir modelin özelliklerini kullanarak benzer performans göstermesi, derin öğrenme modellerinin "özellik çıkarıcı" olarak kullanılıp, ardından daha hafif ve hızlı sınıflandırıcılarla tamamlanabileceği fikrini desteklemektedir. Bu yaklaşım, sistemin genel karmaşıklığını azaltırken, elde edilen doğruluktan ödün vermemeyi mümkün kılmaktadır.


Kullanıcı Arayüzü ve Uygulama

Proje kapsamında geliştirilen Gradio tabanlı kullanıcı arayüzü, oluşturulan yapay zeka modellerinin son kullanıcılar tarafından kolayca test edilebilmesini ve tahmin sonuçlarının anlaşılır bir şekilde görselleştirilmesini sağlamaktadır. Bu arayüz, teknik bilgiye sahip olmayan kişilerin bile sistemin işleyişini gözlemlemesine olanak tanır ve model çıktılarının şeffaflığını artırır. Bu şeffaflık, özellikle Relief ile seçilen yorumlanabilir özelliklerin önemi göz önüne alındığında kritik bir değer taşır. Kullanıcı, her iki modelin de aynı görüntüden yola çıkarak nasıl farklı veya benzer tahminler yaptığını, olasılık dağılımları üzerinden karşılaştırmalı olarak görebilir.


Arayüz Tasarımı ve İşlevsellik

Gradio kütüphanesi kullanılarak oluşturulan bu uygulama, basit ve sezgisel bir yapıya sahiptir. Ana arayüzde, kullanıcının bir göz görüntüsünü yükleyebileceği bir görüntü giriş bileşeni (Input Image)

bulunmaktadır. Görüntü yüklendikten sonra, ön tanımlı bir tahmin fonksiyonu (predict_eye_condition) devreye girer ve iki farklı modelin tahminlerini eş zamanlı olarak hesaplar. Bu eş zamanlı sunum, boyut indirgeme yöntemlerinin performansa etkisini anında gözlemlene olanağı sunar.



Şekil30: Arayüz Görüntüsü



Şekil31: Arayüz üzerinden yapılan tahmin görüntüsü

Arayüzde ayrıca, projenin amacı, kullanılan modeller hakkında kısa bilgiler ve bir sorumluluk reddi yazısı bulunmaktadır. Bu, uygulamanın yalnızca demo amaçlı olduğu ve tıbbi teşhis yerine geçmediği vurgulanarak etik ilkelere uyulmasını sağlar. Bu arayüz, projenin teorik çıktılarının pratik bir uygulamaya nasıl dönüştürüldüğünü ve kullanıcıların yapay zeka destekli teşhis süreçleriyle nasıl etkileşime geçebileceğini açıkça göstermektedir

KAYNAKLAR

- [1] Hatanaka, Y., Noudo, A., Muramatsu, C., Sawada, A., Hara, T., Yamamoto, T., & Fujita, H. (2010, March). Vertical cup-to-disc ratio measurement for diagnosis of glaucoma on fundus images. In *Medical Imaging 2010: Computer-Aided Diagnosis* (Vol. 7624, pp. 945-952). SPIE
- [2] Carrillo, J., Bautista, L., Villamizar, J., Rueda, J., & Sanchez, M. (2019, April). Glaucoma detection using fundus images of the eye. In *2019 XXII Symposium on Image, Signal Processing and Artificial Vision (STSIVA)* (pp. 1-4). IEEE
- [3] J. Carrillo, L. Bautista, J. Villamizar, J. Rueda, ve M. Sanchez, “Glaucoma detection using fundus images of the eye”, *2019 XXII Symposium on Image, Signal Processing and Artificial Vision (STSIVA)*, IEEE, 2019, ss. 1–4.
- [4] Carrillo, J., Bautista, L., Villamizar, J., Rueda, J., & Sanchez, M. (2019, April). Glaucoma detection using fundus images of the eye. In *2019 XXII Symposium on Image, Signal Processing and Artificial Vision (STSIVA)* (pp. 1-4). IEEE.
- [5] Dhumane, C. D., & Patil, S. B. (2015). Automated glaucoma detection using cup to disc ratio. *International Journal of Innovative Research in Science, Engineering and Technology*, 4(7), 5209-5216.
- [6] Melo, T., Mendonça, A. M., & Campilho, A. (2020). Microaneurysm detection in color eye fundus images for diabetic retinopathy screening. *Computers in Biology and Medicine*, 126, 103995. <https://doi.org/10.1016/j.combiomed.2020.103995>
- [7] Tanyıldızı, E., & Okur, S. (2016). Retina Görüntülerindeki Kan Damarlarının Belirlenmesi. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 28(2), 15-22. <https://doi.org/10.35234/fumbd.314594>
- [8] H. A. Dhage, R. K. Patil, V. V. Gohokar, and D. B. Kulkarni. (2015). Detection and counting the microaneurysms using image processing techniques. *International Journal of Computer Applications*, 117(16), 34-39.
- [9] Maison, T., Lestari, T., & Luthfi, A. (2019). Retinal blood vessel segmentation using Gaussian filter. *Journal of Physics: Conference Series*, 1376, 012023. <https://doi.org/10.1088/1742-6596/1376/1/012023>

- [10] Spencer, T., Olson, J. A., McHardy, K. C., Sharp, P. F., & Forrester, J. V. (1996). An image-processing strategy for the segmentation and quantification of microaneurysms in fluorescein angiograms of the ocular fundus. *Computers and Biomedical Research*, 29(3), 284-302. <https://doi.org/10.1006/cbmr.1996.0021>
- [11] Sreng, S., Maneerat, N., & Hamamoto, K. (2017). Automated microaneurysms detection in fundus images using image segmentation. *2017 IEEE Conference on Biomedical Engineering (BME)*, 284-302. <https://doi.org/10.1109/BME.2017.7951210>
- [12] Nagar, S. J., & Gondaliya, N. (2025). Eye Diseases Classification Using Transfer Learning Technique of Deep Neural Network. *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, 11(1), 1247–1257. <https://doi.org/10.32628/CSEIT251112124>
- [13] Babaqi, T., Jaradat, M., Yildirim, A. E., Al-Nimer, S. H., & Won, D. (2023, Temmuz). Eye disease classification using deep learning techniques. In K. Babski-Reeves, B. Eksioglu, & D. Hampton (Eds.), *Proceedings of the IISE Annual Conference & Expo 2023*. <https://doi.org/10.48550/arXiv.2307.10501>
- [14] Jatmoko, C., Lestiawan, H., Agustina, F., & Erawan, L. (2024). Comparative study of classification of eye disease types using DenseNet and EfficientNetB3. *Kinetik: Game Technology, Information System, Computer Network, Computing, Electronics, and Control*, 9(3), 239-246. <https://doi.org/10.22219/kinetik.v9i3.1931>
- [15] Chavan, S., Deshpande, S., & Sohani, M. (2024). Comprehensive eye disease classification using deep learning. *Frontiers in Health Informatics*, 13(6), 1300-1313.